

Sveučilište Jurja Dobrile u Puli

Fakultet informatike u Puli

Analiza bankovnih transakcija i detekcija prijevara

Student: Petra Puljić

Studijski smjer: Informatika

Kolegij: Skladišta i rudarenje podataka

Nositelj: doc.dr.sc. Goran Oreški

|                                                                        |           |
|------------------------------------------------------------------------|-----------|
| <b>1. UVOD.....</b>                                                    | <b>1</b>  |
| <b>2. SKUP PODATAKA.....</b>                                           | <b>1</b>  |
| 2.1. Opis poslovnog problema.....                                      | 2         |
| <b>3. OSNOVNA ANALIZA PODATAKA.....</b>                                | <b>3</b>  |
| <b>4. IZRADA RELACIJSKOG MODELA I BAZE PODATAKA.....</b>               | <b>9</b>  |
| 4.1. Priprema podataka za bazu.....                                    | 9         |
| 4.2. ER dijagram.....                                                  | 10        |
| 4.3. EER dijagram i implementacija u MySQL-u.....                      | 11        |
| 4.4. Učitavanje i provjera podataka.....                               | 12        |
| <b>5. DIMENZIJSKI MODEL PODATAKA.....</b>                              | <b>14</b> |
| 5.1. Odabir poslovnog procesa i granularnosti.....                     | 14        |
| 5.2. Tablica činjenica i mjere.....                                    | 15        |
| 5.3. Dimenzije i hijerarhije.....                                      | 16        |
| 5.4. Napredne značajke modela.....                                     | 17        |
| 5.5. Star schema dijagram.....                                         | 17        |
| <b>6. ETL PROCES I PUNJENJE SKLADIŠTA PODATAKA.....</b>                | <b>19</b> |
| 6.1. Izvori podataka.....                                              | 20        |
| 6.2. Extract faza: dohvat i spajanje podataka.....                     | 21        |
| 6.3. Transform faza: priprema podataka za skladište.....               | 22        |
| 6.4. Load faza: punjenje dimenzijskih tablica i tablice činjenica..... | 23        |
| 6.5. Provjera uspješnosti punjenja.....                                | 24        |
| <b>7. OLAP ANALIZA I VIZUALIZACIJA U POWER BI-JU.....</b>              | <b>26</b> |
| 7.1. Povezivanje skladišta podataka s Power BI-jem.....                | 27        |
| 7.2. Definiranje mjera za analizu.....                                 | 28        |
| 7.3. Pregled bankovnih transakcija.....                                | 29        |
| 7.4. Analiza prijevornih transakcija.....                              | 31        |
| 7.5. OLAP operacije nad podacima.....                                  | 32        |
| 7.6. Zaključak OLAP analize.....                                       | 35        |
| <b>8. ZAKLJUČAK.....</b>                                               | <b>36</b> |

## 1. UVOD

U današnje vrijeme podaci imaju veliku važnost u gotovo svim područjima poslovanja. Svaki sustav svakodnevno stvara velike količine podataka, ali ti podaci sami po sebi ne znače puno ako nisu pravilno organizirani i pripremljeni za analizu. Zbog toga se koriste skladišta podataka i alati poslovne inteligencije, koji omogućuju da se podaci prikažu na pregledan način i da se iz njih mogu donijeti korisni zaključci.

U ovom projektu obrađuju se podaci vezani uz bankovne transakcije. Tema je zanimljiva zato što se na temelju takvih podataka mogu pratiti različiti obrasci ponašanja korisnika, vrste transakcija, iznosi transakcija i moguće prijevarne aktivnosti. Cilj projekta nije samo pohraniti podatke, nego ih pripremiti tako da se kasnije mogu analizirati i prikazati kroz izvještaje i vizualizacije.

Projekt prikazuje cijeli proces rada s podacima, od početne analize i provjere strukture podataka, preko izrade modela baze i skladišta podataka, do učitavanja podataka i njihove analize u Power BI alatu. Na taj način se povezuje teorija iz kolegija sa stvarnom implementacijom, odnosno pokazuje se kako se podaci iz izvornog oblika mogu pretvoriti u oblik koji je koristan za donošenje odluka.

Konačni cilj projekta je dobiti pregledan analitički sustav koji omogućuje praćenje bankovnih transakcija, usporedbu različitih kategorija podataka i jednostavnije prepoznavanje sumnjivih ili prijevarnih transakcija.

## 2. SKUP PODATAKA

Za izradu ovog projekta odabran je skup podataka pod nazivom **Bank Transaction Fraud Detection**. Skup podataka preuzet je s web stranice Kaggle, koja se često koristi

za pronalazak javno dostupnih skupova podataka za analizu, strojno učenje i izradu projekata iz područja podatkovne znanosti.

Odabrani skup podataka odnosi se na bankovne transakcije i sadrži podatke koji omogućuju analizu različitih obilježja transakcija, korisnika, računa, uređaja, lokacija i mogućih prijevornih aktivnosti. Zbog toga je prikladan za ovaj projekt jer se na temelju njega može izraditi relacijska baza podataka, skladište podataka i kasnije provesti analiza pomoću OLAP operacija i vizualizacija.

Skup podataka dostupan je na poveznici:

<https://www.kaggle.com/datasets/marusagar/bank-transaction-fraud-detection>

## 2.1. Opis poslovnog problema

Bankovni sustavi svakodnevno obrađuju velik broj transakcija, kao što su uplate, isplate, prijenosi novca i kartična plaćanja. Zbog velike količine podataka postaje teško ručno pratiti sve transakcije i na vrijeme prepoznati one koje mogu biti sumnjive ili prijevorne. Problem se dodatno povećava jer se prijevarne transakcije često mogu razlikovati od uobičajenih samo po određenim obrascima, npr. prema iznosu, vrsti transakcije, uređaju, lokaciji ili ponašanju korisnika.

Poslovni problem ovog projekta odnosi se na potrebu za boljim praćenjem i analizom bankovnih transakcija. Cilj nam je omogućiti pregled šire slike: koliko se transakcija događa, koje vrste transakcija su najčešće, gdje se pojavljuje veći broj prijevara i kroz koje uređaje ili kategorije se one najviše događaju.

U operativnom sustavu podaci se najčešće koriste za svakodnevnu obradu transakcija, dok za analizu i donošenje zaključaka trebaju biti posebno pripremljeni. Zato je potrebno podatke organizirati u oblik pogodan za izvještavanje i analizu. Kroz skladište podataka i vizualizacije moguće je lakše uočiti trendove, usporediti različite kategorije i dobiti korisne informacije koje mogu pomoći u donošenju boljih poslovnih i sigurnosnih odluka.

Ovaj projekt zato rješava problem pretvaranja sirovih transakcijskih podataka u pregledan analitički sustav koji omogućuje jednostavnije praćenje bankovnih transakcija i prepoznavanje mogućih prijevornih aktivnosti.

### 3. OSNOVNA ANALIZA PODATAKA

U početnom dijelu projekta napravljena je osnovna analiza odabranog skupa podataka u Pythonu, pomoću biblioteke pandas i Jupyter Notebook okruženja. Cilj ovog koraka bio je upoznati se sa strukturom podataka prije daljnje obrade i provjeriti je li skup podataka prikladan za izradu baze podataka, skladišta podataka i kasniju analizu.

Prvi korak bio je učitavanje CSV datoteke u DataFrame. DataFrame predstavlja tablični oblik podataka u pandas biblioteci, što znači da se podaci mogu pregledavati i obrađivati po retcima i stupcima. Nakon učitavanja prikazano je prvih pet redaka kako bi se dobio početni uvid u izgled skupa podataka i vrste informacija koje sadrži.

```
# Učitavanje potrebnih biblioteka
import pandas as pd

# Učitavanje podataka iz CSV datoteke
PATH = "C:\\Users\\Petra\\Desktop\\FIPU\\3\\SRP\\Bank_Transaction_Fraud_Detection.csv"

# Učitavanje prvih 2000 redova
# data = pd.read_csv(PATH, delimiter=',', nrows=2000)

# Učitavanje cijelog dataseta
data = pd.read_csv(PATH, delimiter=',')

# Ispis prvih 5 redova
print(data.head())
```

|   | Customer_ID                          | Customer_Name       | Gender | Age | \ |
|---|--------------------------------------|---------------------|--------|-----|---|
| 0 | d5f6ec07-d69e-4f47-b9b4-7c58ff17c19e | Osha Tella          | Male   | 60  |   |
| 1 | 7c14ad51-781a-4db9-b7bd-67439c175262 | Hredhaan Khosla     | Female | 51  |   |
| 2 | 3a73a0e5-d4da-45aa-85f3-528413900a35 | Ekani Nazareth      | Male   | 20  |   |
| 3 | 7902f4ef-9050-4a79-857d-9c2ea3181940 | Yamini Ramachandran | Female | 57  |   |
| 4 | 3a4bba70-d9a9-4c5f-8b92-1735fd8c19e9 | Kritika Rege        | Female | 43  |   |

|   | State       | City               | Bank_Branch               | Account_Type | \ |
|---|-------------|--------------------|---------------------------|--------------|---|
| 0 | Kerala      | Thiruvananthapuram | Thiruvananthapuram Branch | Savings      |   |
| 1 | Maharashtra | Nashik             | Nashik Branch             | Business     |   |
| 2 | Bihar       | Bhagalpur          | Bhagalpur Branch          | Savings      |   |
| 3 | Tamil Nadu  | Chennai            | Chennai Branch            | Business     |   |
| 4 | Punjab      | Amritsar           | Amritsar Branch           | Savings      |   |

|   | Transaction_ID                       | Transaction_Date | ... | \ |
|---|--------------------------------------|------------------|-----|---|
| 0 | 4fa3208f-9e23-42dc-b330-844829d0c12c | 23-01-2025       | ... |   |
| 1 | c9de0c06-2c4c-40a9-97ed-3c7b8f97c79c | 11-01-2025       | ... |   |
| 2 | e41c55f9-c016-4ff3-872b-cae72467c75c | 25-01-2025       | ... |   |
| 3 | 7f7ee11b-ff2c-45a3-802a-49bc47c02ecb | 19-01-2025       | ... |   |
| 4 | f8e6ac6f-81a1-4985-bf12-f60967d852ef | 30-01-2025       | ... |   |

|   | Merchant_Category | Account_Balance | Transaction_Device | \ |
|---|-------------------|-----------------|--------------------|---|
| 0 | Restaurant        | 74557.27        | Voice Assistant    |   |
| 1 | Restaurant        | 74622.66        | POS Mobile Device  |   |
| 2 | Groceries         | 66817.99        | ATM                |   |
| 3 | Entertainment     | 58177.08        | POS Mobile App     |   |
| 4 | Entertainment     | 16108.56        | Virtual Card       |   |

|   | Transaction_Location       | Device_Type | Is_Fraud | Transaction_Currency | \ |
|---|----------------------------|-------------|----------|----------------------|---|
| 0 | Thiruvananthapuram, Kerala | POS         | 0        | INR                  |   |
| 1 | Nashik, Maharashtra        | Desktop     | 0        | INR                  |   |
| 2 | Bhagalpur, Bihar           | Desktop     | 0        | INR                  |   |
| 3 | Chennai, Tamil Nadu        | Mobile      | 0        | INR                  |   |
| 4 | Amritsar, Punjab           | Mobile      | 0        | INR                  |   |

|   | Customer_Contact | Transaction_Description | Customer_Email          |
|---|------------------|-------------------------|-------------------------|
| 0 | +9198579XXXXXX   | Bitcoin transaction     | oshaXXXX@XXXXX.com      |
| 1 | +9191074XXXXXX   | Grocery delivery        | hredhaanXXXX@XXXXXX.com |
| 2 | +9197745XXXXXX   | Mutual fund investment  | ekaniXXX@XXXXXX.com     |
| 3 | +9195889XXXXXX   | Food delivery           | yaminiXXXX@XXXXXX.com   |
| 4 | +9195316XXXXXX   | Debt repayment          | kritikaXXX@XXXXXX.com   |

[5 rows x 24 columns]

Nakon toga provjerena je veličina skupa podataka. Skup sadrži 200 000 redaka i 24 stupca, što znači da zadovoljava uvjet da ima više od 15 000 redaka i više od 20 stupaca. Zbog toga se može zaključiti da je skup dovoljno velik za daljnju obradu i analizu.

```
# Ispis dimenzija skupa podataka
print(data.shape)
```

```
(200000, 24)
```

Zatim su ispisani nazivi svih stupaca kako bi se vidjelo koje se informacije nalaze u skupu podataka. Stupci opisuju korisnike, račune, bankovne poslovnice, transakcije, trgovce, uređaje, lokacije i oznaku je li transakcija prijeverna. Time se vidi da skup podataka ne sadrži samo jednu vrstu informacija, nego povezuje više različitih dijelova bankovnog sustava.

```
# Ispis imena stupaca
print(data.columns.values)

['Customer_ID' 'Customer_Name' 'Gender' 'Age' 'State' 'City' 'Bank_Branch'
 'Account_Type' 'Transaction_ID' 'Transaction_Date' 'Transaction_Time'
 'Transaction_Amount' 'Merchant_ID' 'Transaction_Type' 'Merchant_Category'
 'Account_Balance' 'Transaction_Device' 'Transaction_Location'
 'Device_Type' 'Is_Fraud' 'Transaction_Currency' 'Customer_Contact'
 'Transaction_Description' 'Customer_Email']
```

Posebno je provjeren broj nedostajućih vrijednosti po stupcu korištenjem metode `.isna().sum()`. Ova provjera je važna jer nedostajuće vrijednosti mogu stvarati probleme u kasnijoj obradi podataka. U ovom skupu podataka nisu pronađene nedostajuće vrijednosti, što znači da u početnom koraku nije bilo potrebno dodatno popunjavati ili uklanjati podatke zbog praznih vrijednosti.

```
: # Ispis imena stupaca i nedostajućih vrijednosti
print(data.isna().sum())
```

```
Customer_ID          0
Customer_Name        0
Gender               0
Age                 0
State               0
City                0
Bank_Branch         0
Account_Type        0
Transaction_ID       0
Transaction_Date     0
Transaction_Time     0
Transaction_Amount   0
Merchant_ID         0
Transaction_Type     0
Merchant_Category    0
Account_Balance      0
Transaction_Device   0
Transaction_Location 0
Device_Type         0
Is_Fraud             0
Transaction_Currency 0
Customer_Contact     0
Transaction_Description 0
Customer_Email       0
dtype: int64
```

Nakon toga analiziran je broj jedinstvenih vrijednosti po pojedinim stupcima.

Jedinstvene vrijednosti pokazuju koliko različitih vrijednosti postoji u određenom stupcu.

Ova provjera je korisna jer se tako može vidjeti raznolikost podataka, primjerice koliko postoji različitih tipova transakcija, uređaja, kategorija trgovaca, gradova ili oznaka prijevare.



```

: # Ispis broja jedinstvenih vrijednosti po stupcima
print(data.nunique())

Customer_ID          200000
Customer_Name        142699
Gender                2
Age                  53
State                34
City                 145
Bank_Branch          145
Account_Type         3
Transaction_ID        200000
Transaction_Date      31
Transaction_Time      77856
Transaction_Amount    197978
Merchant_ID           200000
Transaction_Type      5
Merchant_Category     6
Account_Balance       197954
Transaction_Device    20
Transaction_Location  148
Device_Type           4
Is_Fraud              2
Transaction_Currency  1
Customer_Contact      9000
Transaction_Description 172
Customer_Email        4779
dtype: int64

```

Nakon broja jedinstvenih vrijednosti prikazane su i frekvencije vrijednosti po stupcima. Frekvencije pokazuju koliko se puta pojedina vrijednost pojavljuje u određenom stupcu. Za to je korištena petlja koja prolazi kroz sve stupce skupa podataka i za svaki stupac ispisuje vrijednosti te broj njihovih pojavljivanja. Budući da je rezultat ispisa dugačak, u dokumentaciji je prikazan samo kod, dok se potpuni ispis nalazi u Jupyter Notebooku.

```

# Ispis broja jedinstvenih vrijednosti po stupcima
for column in data.columns:
    print("COLUMN:", column)
    print(data[column].value_counts())
    print("Ukupno:", data[column].value_counts().sum())
    print("-" * 50)
    input("...")

```

Zatim su provjereni tpovi podataka pomoću `.dtypes`. Ova provjera je važna jer pokazuje koji su stupci tekstualni, a koji su numerički. Na temelju tipova podataka može se zaključiti koji se stupci mogu koristiti za izračune, a koji se više koriste za opisivanje i grupiranje podataka.

```
: # Ispis tipova podataka po stupcima (ana
print(data.dtypes)
```

```
Customer_ID           object
Customer_Name         object
Gender                object
Age                   int64
State                 object
City                  object
Bank_Branch           object
Account_Type          object
Transaction_ID         object
Transaction_Date       object
Transaction_Time       object
Transaction_Amount     float64
Merchant_ID           object
Transaction_Type       object
Merchant_Category      object
Account_Balance        float64
Transaction_Device     object
Transaction_Location   object
Device_Type           object
Is_Fraud              int64
Transaction_Currency   object
Customer_Contact       object
Transaction_Description object
Customer_Email         object
dtype: object
```

Iz ispisa tipova podataka vidljivo je da skup sadrži i kvantitativne i kvalitativne podatke. Kvantitativni podaci su brojčani podaci, kao što su Age, Transaction\_Amount, Account\_Balance i Is\_Fraud. Oni se mogu koristiti za izračune, usporedbe i izradu mjera u kasnijoj analizi. Kvalitativni podaci su opisni podaci, kao što su Gender, State, City, Account\_Type, Transaction\_Type, Merchant\_Category, Device\_Type i Transaction\_Currency. Oni se mogu koristiti za grupiranje i filtriranje podataka.

Skup podataka ima vremensku dimenziju jer sadrži stupce Transaction\_Date i Transaction\_Time. To je važno za daljnju analizu jer omogućuje promatranje transakcija kroz vrijeme, primjerice po danima, mjesecima ili drugim razdobljima.

Na temelju provedene osnovne analize može se zaključiti da je skup podataka prikladan za nastavak projekta. Skup je dovoljno velik jer sadrži 200 000 redaka i 24 stupca, nema nedostajućih vrijednosti te uključuje različite vrste podataka, poput podataka o korisnicima, računima, transakcijama, uređajima, lokacijama i prijevarama. Također

sadrži kvantitativne i kvalitativne podatke te vremensku dimenziju kroz datum i vrijeme transakcije.

Ovim korakom dobiven je uvid u strukturu i kvalitetu podataka, što je bilo potrebno prije izrade relacijskog modela i daljnje pripreme podataka za skladište podataka.

## 4. IZRADA RELACIJSKOG MODELA I BAZE PODATAKA

Nakon osnovne analize podataka sljedeći korak bio je izrada relacijskog modela i baze podataka. Cilj ovog dijela projekta bio je podatke iz početne CSV datoteke organizirati u više povezanih tablica. Na taj način se izbjegava spremanje svih podataka u jednu veliku tablicu i omogućuje se jasnija struktura podataka.

U ovom checkpointu definirani su entiteti, atributi, veze između entiteta i kardinalnosti veza. Nakon toga izrađen je ER dijagram kao konceptualni model podataka, zatim EER dijagram kao logički model, a na kraju je model implementiran u MySQL bazi podataka.

### 4.1. Priprema podataka za bazu

Prije izrade baze podataka bilo je potrebno pripremiti podatke za daljnji rad. Početni skup podataka podijeljen je na dva dijela u omjeru 80/20. Veći dio podataka, odnosno 80% skupa, korišten je za izradu i punjenje relacijske MySQL baze podataka. Taj dio sadrži 160 000 redaka. Preostalih 20% skupa, odnosno 40 000 redaka, spremljeno je u CSV obliku i kasnije se koristi kao drugi izvor podataka u ETL procesu.

Na taj način relacijska baza predstavlja jedan izvor podataka, dok preostali CSV dio predstavlja drugi izvor podataka za punjenje skladišta podataka. Time je dobiven dovoljno velik skup podataka za izradu baze i provjeru odnosa između tablica.

```
df20 = df.sample(frac=0.2, random_state=1)
df80 = df.drop(df20.index)

print("CSV size 80:", df80.shape)
print("CSV size 20:", df20.shape)
print("Ukupno:", len(df80) + len(df20))
```

```
CSV size 80: (160000, 24)
CSV size 20: (40000, 24)
Ukupno: 200000
```


```
df80.to_csv("Bank_Transaction_Fraud_Detection_PROCESSED.csv", index=False) # ide u mysql
df20.to_csv("Bank_Transaction_Fraud_Detection_PROCESSED_20.csv", index=False) # ostaje kasnije za etl
```

## 4.2. ER dijagram

Nakon pripreme podataka definirani su glavni entiteti i njihovi atributi. Entitet predstavlja važan objekt ili pojam iz stvarnog sustava koji želimo spremiti u bazu podataka. U ovom projektu neki od glavnih entiteta su korisnik, račun, transakcija, trgovac, vrsta transakcije, uređaj, lokacija i valuta.

Središnji entitet u modelu je `Bank_Transaction`, jer se cijeli skup podataka temelji na bankovnim transakcijama. Ostali entiteti povezani su s transakcijom i opisuju dodatne informacije, npr. kojem računu transakcija pripada, koji je tip transakcije, preko kojeg uređaja je izvršena i na kojoj lokaciji se dogodila.


ER dijagram prikazuje konceptualni model podataka, odnosno osnovne entitete i veze između njih. Na primjer, jedan korisnik može imati više računa, jedan račun može imati više transakcija, jedna kategorija trgovca može imati više trgovaca, a jedan tip uređaja može se odnositi na više konkretnih uređaja.



### 4.3. EER dijagram i implementacija u MySQL-u

Nakon ER dijagrama izrađen je EER dijagram, koji predstavlja detaljniji logički model baze podataka. Za razliku od ER dijagrama, EER dijagram prikazuje tablice u obliku bližem stvarnoj implementaciji u bazi. U njemu su prikazani primarni ključevi, strani ključevi i tipovi podataka.

Model je implementiran u MySQL sustavu za upravljanje bazom podataka. Svaki entitet iz modela pretvoren je u zasebnu tablicu, a veze između tablica ostvarene su pomoću stranih ključeva. Na primjer, tablica `bank_transaction` sadrži strane ključeve koji je povezuju s tablicama `account`, `merchant`, `transaction_type`, `transaction_device`, `transaction_location` i `currency`.



#### 4.4 Učitavanje i provjera podataka

Nakon implementacije modela u MySQL-u podaci su učitani u relacijsku bazu podataka. Prvo su učitane pomoćne tablice, kao što su tablice za države, gradove, poskovnice, tipove računa, tipove transakcija, kategorije trgovaca, tipove uređaja i valute. Nakon

toga učitane su glavne tablice, uključujući korisnike, račune, trgovce i bankovne transakcije.

Nakon učitavanja napravljena je provjera broja redaka u svakoj tablici pomoću SQL upita `SELECT COUNT(*)`. Time se provjerilo jesu li podaci uspješno spremljeni u bazu i odgovara li broj zapisa očekivanim vrijednostima. Iz rezultata je vidljivo da glavna tablica `bank_transaction` sadrži 160 000 zapisa, što odgovara broju redaka iz pripremljenog dijela skupa podataka.

```
tables = [
    "state",
    "city",
    "bank_branch",
    "account_type",
    "customer",
    "account",
    "transaction_type",
    "merchant_category",
    "merchant",
    "device_type",
    "transaction_device",
    "transaction_location",
    "currency",
    "bank_transaction"
]

with engine.connect() as connection:
    for table in tables:
        count = connection.execute(text(f"SELECT COUNT(*) FROM {table};")).fetchone()[0]
        print(table, ":", count)

state : 34
city : 148
bank_branch : 148
account_type : 3
customer : 160000
account : 160000
transaction_type : 5
merchant_category : 6
merchant : 160000
device_type : 4
transaction_device : 20
transaction_location : 148
currency : 1
bank_transaction : 160000
```

Na kraju je ovim korakom izrađena relacijska baza podataka koja je organizirana kroz više međusobno povezanih tablica. Time su podaci pripremljeni za sljedeći dio projekta, odnosno izradu dimenzijskog modela i skladišta podataka.

## 5. DIMENZIJSKI MODEL PODATAKA

Nakon izrade relacijske baze podataka, sljedeći korak bio je izrada dimenzijskog modela podataka. Relacijski model je prikladan za spremanje i organizaciju podataka, dok je dimenzijski model prikladniji za analizu, izvještavanje i kasniju izradu vizualizacija.

U ovom dijelu projekta izrađena je star schema. U tom modelu u središtu se nalazi tablica činjenica, a oko nje dimenzijske tablice. Tablica činjenica sadrži podatke koji se mogu mjeriti i analizirati, dok dimenzijske tablice opisuju kontekst tih podataka.

Za ovaj projekt središnji poslovni proces je bankovna transakcija, jer se cijeli skup podataka temelji na zapisima o transakcijama. Zbog toga je glavna tablica činjenica nazvana `fact_bank_transaction`, a oko nje su definirane dimenzije koje opisuju korisnika, račun, trgovca, uređaj, datum, vrstu transakcije, lokaciju i valutu.

### 5.1. Odabir poslovnog procesa i granularnosti

Prvi korak u izradi dimenzijskog modela bio je odabir poslovnog procesa koji će se analizirati. U ovom projektu odabran je proces izvršavanja bankovne transakcije. To znači da se analiza temelji na pojedinačnim transakcijama, njihovim iznosima, korisnicima, računima, uređajima i mogućim prijevarama.

Nakon toga definirana je granularnost tablice činjenica. Granularnost označava razinu detalja koja se sprema u tablici činjenica. U ovom modelu granularnost je postavljena tako da jedan redak u tablici `fact_bank_transaction` predstavlja jednu bankovnu transakciju.



Ovakva granularnost omogućuje detaljnu analizu podataka jer se svaka transakcija može promatrati zasebno, a podaci se kasnije mogu grupirati prema različitim dimenzijama (datum, tip transakcije, uređaj, lokacija ili trgovac).

## 5.2. Tablica činjenica i mjere

Nakon definiranja poslovnog procesa i granularnosti odabrana je tablica činjenica. Tablica činjenica nalazi se u središtu dimenzijskog modela i sadrži podatke koji se mogu analizirati i povezivati s dimenzijama.

U ovom projektu tablica činjenica je `fact_bank_transaction`. Ona predstavlja pojedinačne bankovne transakcije i povezuje se s dimenzijama preko surogat ključeva. Na taj način svaka transakcija može biti analizirana prema korisniku, računu, datumu, trgovcu, uređaju, vrsti transakcije, lokaciji i valuti.

Glavna mjera u tablici činjenica je `transaction_amount`, odnosno iznos pojedinačne transakcije. Ta mjera je važna jer se može zbrajati, prosječiti i uspoređivati po različitim dimenzijama. Osim nje, u tablici se nalaze i dodatne mjere: `account_balance`, `is_fraud` i `transaction_count`.

Mjera `account_balance` prikazuje stanje računa u trenutku transakcije. Atribut `is_fraud` koristi se kao indikator prijave jer pokazuje je li određena transakcija označena kao prijevna. Mjera `transaction_count` dodana je kao pomoćna mjera s vrijednošću 1 za svaku transakciju, kako bi se kasnije jednostavno mogao izračunati ukupan broj transakcija.

U tablici činjenica zadržan je i atribut `transaction_code`. On predstavlja degeneriranu dimenziju jer opisuje pojedinačnu transakciju, ali za njega nije izrađena posebna dimenzijska tablica. Zbog toga ostaje direktno u tablici činjenica.

### 5.3. Dimenzije i hijerarhije

Nakon definiranja tablice činjenica odabrane su dimenzijske tablice. Dimenzije opisuju kontekst transakcije i uglavnom sadrže kvalitativne podatke. One omogućuju da se transakcije kasnije analiziraju prema različitim kategorijama, primjerice prema korisniku, računu, datumu, trgovcu, uređaju, lokaciji ili vrsti transakcije.

U ovom modelu definirane su dimenzije `dim_date`, `dim_customer`, `dim_account`, `dim_merchant`, `dim_device`, `dim_transaction_type`, `dim_transaction_location` i `dim_currency`.

Dimenzija `dim_date` koristi se za analizu transakcija kroz vrijeme. Dimenzija `dim_customer` opisuje korisnika, dok `dim_account` opisuje račun, vrstu računa i podatke o poslovnici. Dimenzija `dim_merchant` opisuje trgovca i kategoriju trgovca, a `dim_device` uređaj preko kojeg je transakcija izvršena. Ostale dimenzije opisuju vrstu transakcije, lokaciju transakcije i valutu.

U dimenzijama su definirane i hijerarhije. Hijerarhije omogućuju analizu podataka na različitim razinama detalja. Na primjer, vremenska hijerarhija omogućuje analizu po godini, kvartalu, mjesecu i danu. U modelu je definirana hijerarhija `year_number` → `quarter_number` → `month_number` → `day_of_month`.

Druga hijerarhija nalazi se u dimenziji računa i povezuje lokacijske i organizacijske podatke: `state_name` → `city_name` → `bank_branch_name` → `account_type_name`. Ona omogućuje analizu transakcija prema državi, gradu, poslovnici i tipu računa.

Treća hijerarhija definirana je u dimenziji trgovca: `merchant_category_name` → `merchant_code`. Ona omogućuje analizu transakcija prema kategoriji trgovca i pojedinom trgovcu.

## 5.4. Napredne značajke modela

U dimenzijski model uključene su i napredne značajke izvedbe kako bi model bio prikladniji za analizu podataka. Jedna od važnih značajki su surogat ključevi. Oni se koriste kao tehnički ključevi u dimenzijskim tablicama i ne ovise direktno o izvornim identifikatorima iz početnog skupa podataka. Primjeri su `customer_tk`, `account_tk`, `merchant_tk` i ostali ključevi koji se koriste za povezivanje tablice činjenica s dimenzijama.

U modelu su definirane i sporo mijenjajuće dimenzije. One se koriste kada se podaci u dimenzijama mogu mijenjati kroz vrijeme, ali je važno zadržati i prijašnje vrijednosti. U ovom projektu takav pristup primijenjen je na dimenzije `dim_customer`, `dim_account` i `dim_merchant`.

Za te dimenzije korišten je SCD Type 2 pristup. To znači da se promjena ne prepisuje preko stare vrijednosti, nego se može spremati nova verzija zapisa. Zbog toga dimenzije sadrže attribute `version`, `date_from`, `date_to` i `is_current`. Na taj način moguće je znati koja je verzija zapisa trenutno aktivna, a koje verzije pripadaju prošlosti.

U modelu je korištena i degenerirana dimenzija `transaction_code`. Ona se nalazi direktno u tablici činjenica `fact_bank_transaction`, jer predstavlja oznaku pojedinačne transakcije, ali za nju nije potrebna posebna dimenzijska tablica.

Osim toga, neke dimenzijske tablice su denormalizirane. To znači da su povezani opisni podaci spojeni u jednu dimenzijsku tablicu kako bi analiza bila jednostavnija. Primjer je `dim_account`, koja sadrži podatke o računu, tipu računa, poslovnici, gradu i državi.


## 5.5. Star schema dijagram

Na kraju je izrađen star schema dijagram. U središtu modela nalazi se tablica činjenica `fact_bank_transaction`, koja sadrži mjere i ključeve za povezivanje s dimenzijama.

Oko nje su raspoređene dimenzijske tablice `dim_date`, `dim_customer`, `dim_account`, `dim_merchant`, `dim_device`, `dim_transaction_type`, `dim_transaction_location` i `dim_currency`.

Ova struktura modela omogućuje jednostavniju analizu podataka jer se sve važne informacije o transakcijama mogu promatrati kroz različite dimenzije. Na taj način moguće je analizirati iznose i broj transakcija prema vremenu, korisnicima, računima, trgovcima, uređajima, lokaciji, vrsti transakcije i valuti.

Star schema je pogodna za analitičke sustave jer pojednostavljuje upite i olakšava kasniju izradu skladišta podataka, OLAP analize i vizualizacija. Time je dimenzijski model u ovom projektu završen i pripremljen za sljedeći korak, odnosno ETL proces i punjenje skladišta podataka.



## 6. ETL PROCES I PUNJENJE SKLADIŠTA PODATAKA

Nakon izrade dimenzijskog modela podataka bilo je potrebno napuniti skladište podataka stvarnim podacima. U ovom dijelu projekta proveden je ETL proces, odnosno proces izdvajanja, transformacije i učitavanja podataka. ETL je važan jer se podaci iz različitih izvora ne mogu odmah koristiti za analizu, nego ih je prvo potrebno dohvatiti,

provjeriti, prilagoditi i zatim spremi u odgovarajuće dimenzijske tablice i tablicu činjenica.

U ovom projektu skladište podataka puni se iz dva izvora. Prvi izvor je relacijska MySQL baza podataka, koja sadrži 80% početnog skupa podataka, odnosno 160 000 transakcija. Drugi izvor je CSV datoteka koja sadrži preostalih 20% početnog skupa podataka, odnosno 40 000 transakcija.

Na taj način ETL proces objedinjuje podatke iz dva različita izvora: relacijske baze i CSV datoteke. Nakon izdvajanja, transformacije i učitavanja, skladište podataka sadrži ukupno 200 000 transakcija.

ETL proces proveden je kroz tri glavne faze. U Extract fazi podaci su dohvaćeni iz izvora, u Transform fazi su pripremljeni i usklađeni za dimenzijski model, a u Load fazi su učitani u skladište podataka. Nakon punjenja napravljena je i provjera unosa podataka kako bi se potvrdilo da su podaci ispravno učitani i da nije došlo do gubitka zapisa.

## 6.1. Izvori podataka

Za punjenje skladišta podataka korištena su dva izvora podataka. Prvi izvor je relacijska baza podataka izrađena u MySQL-u u prethodnom dijelu projekta. U toj bazi nalaze se podaci koji su prethodno organizirani u više povezanih relacijskih tablica, kao što su korisnici, računi, transakcije, trgovci, uređaji, lokacije i ostale pomoćne tablice.

Drugi izvor podataka je CSV datoteka koja sadrži preostalih 20% početnog skupa podataka. Taj dio nije učitani u relacijsku MySQL bazu, nego je namjerno ostavljen u datotečnom obliku kako bi se u ETL procesu mogao koristiti kao zaseban izvor podataka.

MySQL baza sadrži 160 000 transakcija, dok CSV izvor sadrži 40 000 transakcija. Ta dva izvora zajedno čine početni skup od 200 000 transakcija. U ETL procesu podaci iz

oba izvora dovode se u zajednički oblik, objedinjuju u staging području i zatim učitavaju u skladište podataka.

## 6.2. Extract faza: dohvat i spajanje podataka

Nakon definiranja izvora podataka započinje Extract faza ETL procesa. Extract faza odnosi se na dohvat podataka iz izvornih sustava. U ovom koraku podaci se još ne učitavaju direktno u skladište podataka, nego se prvo izdvajaju iz izvora i pripremaju za daljnju obradu.

U ovom projektu podaci su dohvaćeni iz dva izvora. Prvi izvor je relacijska MySQL baza `bank_fraud_db`, koja je izrađena u prethodnom dijelu projekta. Budući da su podaci u toj bazi raspoređeni u više povezanih tablica, korišten je SQL upit kojim su podaci spojeni u jedan zajednički oblik prikladan za daljnju obradu.

Drugi izvor je CSV datoteka koja sadrži preostalih 20% početnog skupa podataka. Iz CSV datoteke dohvaćeni su podaci koji predstavljaju dodatne transakcije koje nisu učitane u relacijsku MySQL bazu.

Nakon dohvaćanja podataka iz oba izvora, MySQL podaci i CSV podaci pripremljeni su u isti oblik, odnosno usklađeni su nazivi stupaca i struktura podataka. Nakon toga su objedinjeni u zajednički staging dataframe. Staging dataframe predstavlja privremeno pripremno područje podataka prije transformacije. U njemu se podaci iz izvora nalaze na jednom mjestu i mogu se dalje provjeravati, čistiti i prilagođavati dimenzijskom modelu.

```
mysql_staging_part = mysql_source_df.copy()
mysql_staging_part["source_system"] = "MySQL 80%"

csv_staging_part = csv_source_aligned_df.copy()
csv_staging_part["source_system"] = "CSV 20%"

staging_df = pd.concat(
    [mysql_staging_part, csv_staging_part],
    ignore_index=True
)

print("Broj redaka i stupaca nakon spajanja dva izvora u staging dataframe:")
print(staging_df.shape)

display(staging_df.head())
```

Broj redaka i stupaca nakon spajanja dva izvora u staging dataframe:  
(200000, 39)

Za objedinjavanje nije korišteno spajanje po istim transakcijama, nego se radi o dodavanju redaka iz CSV izvora na redove iz MySQL izvora. MySQL izvor sadrži 160 000 redaka, CSV izvor sadrži 40 000 redaka, a staging dataframe nakon objedinjavanja sadrži ukupno 200 000 redaka. Takav način spajanja omogućuje da se zadrže sve transakcije iz MySQL izvora, što je važno kako tijekom ETL procesa ne bi došlo do gubitka zapisa.

Dobiveni staging dataframe kasnije se koristi kao ulaz za Transform fazu. Time je završena Extract faza jer su podaci iz oba izvora dohvaćeni i spojeni u oblik koji se može dalje obrađivati.

### 6.3. Transform faza: priprema podataka za skladište

Nakon Extract faze slijedi Transform faza. U ovoj fazi podaci se pripremaju za učitavanje u skladište podataka. To znači da se provjerava njihova struktura, usklađenost i prikladnost za dimenzijski model koji je prethodno definiran.

U ovom projektu Transform faza provodi se nad staging dataframeom koji je nastao objedinjavanjem MySQL izvora i CSV izvora. Budući da izvori dolaze iz različitih oblika pohrane, bilo je potrebno uskladiti njihovu strukturu prije učitavanja u skladište podataka.



Transformacija je uključivala usklađivanje naziva stupaca, provjeru tipova podataka, pripremu datumskih vrijednosti, pripremu numeričkih vrijednosti i oblikovanje podataka tako da odgovaraju dimenzijskom modelu. Nakon toga podatci su se mogli koristiti za punjenje dimenzijskih tablica i tablice činjenica.

Posebno je važno da staging dataframe nakon transformacije sadrži sve transakcije iz oba izvora: 160 000 transakcija iz MySQL baze i 40 000 transakcija iz CSV datoteke. Time je za punjenje skladišta pripremljeno ukupno 200 000 transakcija. Osim toga, provjerene su i moguće razlike u podacima koji se koriste kao dodatne informacije, kao što su kontakt korisnika, e-mail i opis transakcije.

U Transform fazi podaci su također prilagođeni obliku koji je potreban za punjenje dimenzijskih tablica i tablice činjenica. To uključuje pripremu vrijednosti koje će se kasnije nalaziti u dimenzijama, primjerice podaci o korisnicima, računima, trgovcima, uređajima, vrsti transakcije, lokaciji, valuti i datumu.

Posebna pažnja posvećena je tome da podaci budu konzistentni prije učitavanja u skladište. To je važno jer se u skladištu podataka podaci kasnije koriste za analizu i vizualizacije, pa pogrešno povezani ili neusklađeni podaci mogu dovesti do netočnih rezultata.

Nakon transformacije dobiveni podaci spremni su za Load fazu, odnosno za učitavanje u dimenzijske tablice i tablicu činjenica.

## 6.4. Load faza: punjenje dimenzijskih tablica i tablice činjenica

Nakon što su podaci dohvaćeni i pripremljeni u Transform fazi, slijedi Load faza. U ovoj fazi podaci se učitavaju u skladište podataka, odnosno u tablice koje su definirane u dimenzijskom modelu. Cilj ove faze je napuniti dimenzijske tablice i tablicu činjenica podacima koji su prethodno očišćeni i pripremljeni.

Punjenje skladišta podataka provedeno je u bazi `bank_fraud_dw`. Prvo su učitane dimenzijske tablice, jer one sadrže opisne podatke koji se kasnije koriste za povezivanje s tablicom činjenica. U ovom projektu učitane su dimenzije `dim_date`, `dim_customer`, `dim_account`, `dim_merchant`, `dim_device`, `dim_transaction_type`, `dim_transaction_location` i `dim_currency`.

Tablica činjenica napunjena je podacima iz objedinjenog staging dataframea, koji sadrži transakcije iz oba izvora. To znači da `fact_bank_transaction` nakon učitavanja sadrži ukupno 200 000 transakcija. Ona sadrži podatke o pojedinačnim bankovnim transakcijama, kao i mjere koje se kasnije koriste u analizi. Primjeri mjera su iznos transakcije, stanje računa, oznaka prijave i pomoćna mjera za brojanje transakcija.

Važno je da se tablica činjenica puni nakon dimenzijskih tablica zato što se u njoj nalaze strani ključevi prema dimenzijama. Ti ključevi omogućuju da se svaka transakcija poveže s odgovarajućim korisnikom, računom, trgovcem, datumom, uređajem, lokacijom, vrstom transakcije i valutom.

Tijekom punjenja korišteni su surogat ključevi iz dimenzijskih tablica. Oni služe kao tehnički identifikatori pomoću kojih se tablica činjenica povezuje s dimenzijama. Na taj način se podaci iz izvornog sustava prebacuju u oblik koji je prikladan za analizu u skladištu podataka.

Nakon završetka Load faze skladište podataka sadrži popunjene dimenzijske tablice i tablicu činjenica. Time su podaci spremni za završnu provjeru unosa i kasniju OLAP analizu.

## 6.5. Provjera uspješnosti punjenja

Nakon što su dimenzijske tablice i tablica činjenica napunjene, napravljena je provjera uspješnosti punjenja skladišta podataka. Ovaj korak je važan jer se njime potvrđuje da

tijekom ETL procesa nije došlo do gubitka podataka, pogrešnog povezivanja zapisa ili neispravnog učitavanja u skladište.

Budući da se skladište puni iz dva izvora, očekivani broj redaka u tablici činjenica je 200 000. Taj broj nastaje objedinjavanjem 160 000 transakcija iz MySQL baze i 40 000 transakcija iz CSV izvora. Broj redaka u tablici `fact_bank_transaction` odgovara broju transakcija iz izvora koji je korišten za punjenje skladišta podataka. Time se potvrđuje da su sve transakcije uspješno prenesene u skladište.

Osim broja redaka, provjeren je i broj jedinstvenih transakcija, ukupni iznos transakcija, ukupno stanje računa i broj transakcija označenih kao prijevara. Ove provjere su važne jer nije dovoljno samo provjeriti broj redaka, nego treba potvrditi i da su ključne vrijednosti ostale iste nakon učitavanja.

|   | check                         | source_value | warehouse_value | difference |
|---|-------------------------------|--------------|-----------------|------------|
| 0 | Broj redaka                   | 2.000000e+05 | 2.000000e+05    | 0.0        |
| 1 | Broj jedinstvenih transakcija | 2.000000e+05 | 2.000000e+05    | 0.0        |
| 2 | Zbroj iznosa transakcija      | 9.907603e+09 | 9.907603e+09    | 0.0        |
| 3 | Zbroj stanja računa           | 1.048760e+10 | 1.048760e+10    | 0.0        |
| 4 | Broj fraud transakcija        | 1.008800e+04 | 1.008800e+04    | 0.0        |
| 5 | Zbroj transaction_count       | 2.000000e+05 | 2.000000e+05    | 0.0        |

Također je provjereno postoje li nedostajući strani ključevi prema dimenzijskim tablicama. Budući da nisu pronađeni nedostajući strani ključevi, može se zaključiti da su zapisi u tablici činjenica pravilno povezani s dimenzijama.

Na kraju je napravljena i provjera spajanjem tablice činjenica sa svim dimenzijskim tablicama. Rezultat provjere pokazuje da se svi zapisi iz tablice činjenica uspješno povezuju s pripadajućim dimenzijama. Time je potvrđeno da je skladište podataka ispravno napunjeno i spremno za analitičku obradu.

Na temelju završne provjere može se zaključiti da je ETL proces uspješno proveden. Podaci su ispravno učitani u skladište podataka i nisu izgubljeni tijekom procesa izdvajanja, transformacije i učitavanja.

## 7. OLAP ANALIZA I VIZUALIZACIJA U POWER BI-JU

Nakon što je skladište podataka napunjeno i provjereno, sljedeći korak bio je analiza podataka i izrada vizualizacija. Za taj dio projekta korišten je Power BI, alat koji omogućuje povezivanje s bazom podataka, izradu modela podataka, definiranje mjera i prikaz rezultata kroz izvještaje.

U ovom dijelu projekta podaci iz skladišta `bank_fraud_dw` korišteni su za analizu bankovnih transakcija i prijevornih aktivnosti. Budući da su podaci prethodno organizirani u obliku star sheme, bilo ih je moguće jednostavno povezati u Power BI-ju i koristiti za izradu dashboarda.

Analiza je napravljena kroz više vizualizacija. Prvo je izrađen pregled bankovnih transakcija, gdje se prikazuju osnovni pokazatelji kao što su ukupan broj transakcija, ukupan iznos transakcija, prosječan iznos, broj prijevornih transakcija i udio prijevara. Nakon toga izrađena je posebna stranica za analizu prijevornih transakcija prema uređaju, tipu transakcije, kategoriji trgovca i lokaciji.

Osim osnovnih vizualizacija, u Power BI-ju su prikazane i OLAP operacije. OLAP omogućuje analizu podataka iz različitih perspektiva, primjerice filtriranjem, kombiniranjem više uvjeta, promjenom pogleda na podatke i prelaskom između različitih razina detalja. U ovom projektu prikazane su operacije slice, dice, pivot, drill-down i roll-up.

Cilj ovog dijela projekta je pokazati kako se podaci iz skladišta mogu koristiti za analitičku obradu i donošenje zaključaka. Na temelju izrađenih dashboarda moguće je dobiti pregled transakcija, usporediti različite kategorije i lakše uočiti obrasce povezane s prijevornim transakcijama.

## 7.1. Povezivanje skladišta podataka s Power BI-jem

Prvi korak u izradi analize bio je povezivanje Power BI-ja sa skladištem podataka.

Podaci su prethodno učitani u MySQL bazu `bank_fraud_dw`, koja predstavlja skladište podataka izrađeno u prethodnom checkpointu.

U Power BI su učitane tablica činjenica `fact_bank_transaction` i pripadajuće dimenzijske tablice. Tablica činjenica nalazi se u središtu modela i sadrži podatke o transakcijama, dok dimenzijske tablice opisuju kontekst tih transakcija, primjerice datum, korisnika, račun, trgovca, uređaj, vrstu transakcije, lokaciju i valutu.

Nakon učitavanja tablica provjerene su veze između tablice činjenica i dimenzija. Veze su ostvarene preko surogat ključeva, kao što su `date_tk`, `customer_tk`, `account_tk`, `merchant_tk`, `device_tk`, `transaction_type_tk`, `transaction_location_tk` i `currency_tk`.

Model u Power BI-ju prati strukturu star sheme. To znači da se u središtu nalazi tablica činjenica, a oko nje dimenzijske tablice. Takav model je prikladan za analizu jer omogućuje jednostavno filtriranje, grupiranje i uspoređivanje podataka prema različitim dimenzijama.



Na slici je prikazan model podataka u Power BI-ju. Vidljivo je da je tablica `fact_bank_transaction` povezana s dimenzijskim tablicama, što omogućuje izradu vizualizacija i OLAP analizu nad podacima iz skladišta.

## 7.2. Definiranje mjera za analizu

Nakon povezivanja skladišta podataka s Power BI-jem definirane su osnovne mjere koje se koriste za analizu i izradu vizualizacija. Mjere predstavljaju izračunate vrijednosti koje se dobivaju iz tablice činjenica i koriste se za prikaz glavnih pokazatelja na dashboardu.

U ovom projektu mjere su definirane nad tablicom `fact_bank_transaction`, jer se u njoj nalaze podaci o pojedinačnim bankovnim transakcijama. Na temelju te tablice

moguće je izračunati ukupan broj transakcija, ukupan iznos transakcija, prosječan iznos transakcije, broj prijevornih transakcija i udio prijevara.

Mjera Ukupan broj transakcija koristi se za prikaz ukupnog broja zapisa u tablici činjenica. Ona pokazuje koliko je transakcija ukupno učitano u skladište podataka i koristi se kao osnovni pokazatelj veličine analiziranog skupa podataka.

Mjera Ukupan iznos transakcija prikazuje zbroj svih iznosa transakcija. Ta mjera je važna jer omogućuje pregled ukupne financijske vrijednosti transakcija. Uz nju je definirana i mjera Prosječan iznos transakcije, koja prikazuje prosječnu vrijednost jedne transakcije.

Za analizu prijevara definirana je mjera Broj prijevornih transakcija. Ona broji samo one transakcije kod kojih je atribut `is_fraud` označen kao prijevara. Na temelju te mjere moguće je vidjeti koliko je transakcija u skupu podataka označeno kao sumnjivo ili prijevarno.

Dodatno je definirana mjera Udio prijevara, koja prikazuje odnos između broja prijevornih transakcija i ukupnog broja transakcija. Ova mjera je važna jer sam broj prijevara ne pokazuje dovoljno jasno koliko su prijevare zastupljene u cijelom skupu podataka. Udio prijevara omogućuje bolju interpretaciju jer se izražava kao postotak.

Definirane mjere kasnije se koriste na dashboardima i u OLAP analizi. Pomoću njih moguće je brzo dobiti pregled glavnih vrijednosti, uspoređivati podatke po dimenzijama i analizirati obrasce povezane s prijevornim transakcijama.

### 7.3. Pregled bankovnih transakcija

Nakon definiranja mjera izrađen je prvi dashboard u Power BI-ju. Ova stranica služi za opći pregled bankovnih transakcija i prikazuje najvažnije pokazatelje nad podacima iz skladišta podataka.

Na vrhu dashboarda nalaze se karzice s glavnim vrijednostima. Prikazan je ukupan broj transakcija, ukupan iznos transakcija, prosječan iznos transakcije, udio prijevara i broj prijevernih transakcija. Ove kartice omogućuju brz pregled najvažnijih informacija bez potrebe za detaljnim pregledavanjem tablica.

Iz prikazanih vrijednosti vidi se da skladište podataka sadrži 200 tisuća transakcija. Ukupan iznos transakcija iznosi približno 9,91 milijardu, dok je prosječan iznos transakcije oko 49,54 tisuće. Udio prijevernih transakcija iznosi 5,04%, a broj prijevernih transakcija prikazan je kao približno 10 tisuća.

Osim kartica, na dashboardu su prikazani i grafovi koji omogućuju detaljniji pregled podataka. Linijski graf prikazuje broj transakcija kroz vrijeme, odnosno po danima. Na taj način može se vidjeti kako se broj transakcija mijenja tijekom promatranog razdoblja.

Drugi graf prikazuje broj prijevernih transakcija prema tipu transakcije. Ovaj prikaz omogućuje usporedbu različitih tipova transakcija, kao što su kreditne transakcije, transferi, debitne transakcije, plaćanje računa i podizanje novca. Takva usporedba korisna je jer pokazuje kod kojih se tipova transakcija pojavljuje veći broj prijevara.

## Pregled bankovnih transakcija

**200 tis.**

Ukupan broj transakcija

**9.91 mlrd.**

Ukupan iznos transakcija

**49.54 tis.**

Prosječan iznos transakcije

**5.04%**

Udio prijevara


**10 tis.**

Broj prijevernih transakcija

Broj transakcija kroz vrijeme



Broj prijevernih transakcija prema tipu transakcije





Ovaj dashboard predstavlja početni analitički pregled podataka. Njegova je svrha prikazati osnovne informacije o transakcijama i omogućiti korisniku da brzo dobije sliku o ukupnom broju transakcija, njihovoj vrijednosti i zastupljenosti prijevarena.

## 7.4. Analiza prijevarenih transakcija

Nakon općeg pregleda bankovnih transakcija izrađena je posebna stranica za analizu prijevarenih transakcija. Cilj ove stranice je detaljnije prikazati gdje se prijevarena najviše pojavljuju i prema kojim obilježjima ih je moguće analizirati.

Na ovoj stranici prikazan je udio prijevarena prema tipu uređaja. Ovaj prikaz omogućuje usporedbu različitih uređaja preko kojih su transakcije izvršene, kao što su ATM, Desktop, POS i Mobile. Na taj način može se vidjeti postoji li razlika u udjelu prijevarena ovisno o uređaju koji je korišten.


Drugi prikaz odnosi se na broj prijevarenih transakcija prema kategoriji trgovca. Kategorije trgovaca omogućuju analizu prijevarena prema poslovnom području u kojem se transakcija dogodila, primjerice odjeća, elektronika, namirnice, zdravstvo, restorani i zabava. Takva analiza može pomoći u prepoznavanju kategorija u kojima se češće pojavljuju prijevarena transakcije.

Na dashboardu je prikazana i analiza prijevarena prema lokaciji. Ovaj prikaz omogućuje usporedbu različitih lokacija prema broju prijevarenih transakcija. Time se može vidjeti na kojim se lokacijama pojavljuje veći broj sumnjivih transakcija.

Osim grafova, na stranici se nalaze i rezači za filtriranje podataka prema tipu transakcije i tipu uređaja. Rezači omogućuju korisniku da interaktivno mijenja prikaz podataka i analizira prijevarena samo za određeni tip transakcije ili određeni uređaj.

## Analiza prijevornih transakcija


Udio prijevora prema tipu uređaja



Broj prijevornih transakcija prema kategoriji trgovca



Prijevare prema lokaciji



transaction\_type\_name

- ☐ Bill Payment
- ☐ Credit
- ☐ Debit
- ☐ Transfer
- ☐ Withdrawal

device\_type\_name

- ☐ ATM
- ☐ Desktop
- ☐ Mobile
- ☐ POS

Ova stranica dashboarda korisna je jer omogućuje detaljniji pogled na prijevorne transakcije. Umjesto da se promatra samo ukupan broj prijevora, podaci se mogu analizirati prema uređaju, kategoriji trgovca, lokaciji i tipu transakcije. Time se dobiva bolji uvid u moguće obrasce prijevornog ponašanja.

### 7.5. OLAP operacije nad podacima


Nakon izrade dashboarda u Power BI-ju prikazane su i osnovne OLAP operacije nad podacima. OLAP omogućuje analizu podataka iz različitih perspektiva, što znači da se isti podaci mogu promatrati prema različitim dimenzijama, razinama detalja i filtrima.

U ovom projektu OLAP analiza provedena je nad podacima iz skladišta podataka. Tablica činjenica `fact_bank_transaction` koristi se kao središnja tablica, dok se dimenzijske tablice koriste za filtriranje, grupiranje i promjenu razine detalja. Na taj način moguće je analizirati transakcije prema datumu, tipu transakcije, uređaju, trgovcu, lokaciji i drugim obilježjima.

Prva prikazana operacija je slice. Slice označava izdvajanje jednog dijela podataka prema jednom uvjetu ili jednoj vrijednosti dimenzije. U Power BI-ju je to prikazano pomoću rezača, primjerice kada se odabere samo jedan tip transakcije. Na taj način se cijeli dashboard filtrira i prikazuje samo podatke koji pripadaju odabranoj vrijednosti.

Druga operacija je dice. Dice označava filtriranje podataka prema više uvjeta odjednom. U ovom projektu dice je prikazan filtriranjem podataka prema tipu transakcije i tipu uređaja, primjerice odabirom transakcija tipa Transfer i uređaja Mobile. Time se ne promatra cijeli skup podataka, nego samo manji podskup koji zadovoljava oba uvjeta.

## OLAP operacije nad bankovnim transakcijama





Pivot operacija odnosi se na promjenu pogleda na podatke, odnosno na promjenu načina na koji su dimenzije raspoređene u prikazu. U Power BI-ju se to može prikazati pomoću tabličnog ili matričnog prikaza, gdje se podaci mogu promatrati prema različitim dimenzijama. Na primjer, broj transakcija može se analizirati prema tipu transakcije, uređaju ili kategoriji trgovca, ovisno o tome kako se postave redci, stupci i vrijednosti.

Drill-down operacija omogućuje spuštanje na detaljniju razinu podataka. U ovom projektu to je prikazano kroz vremensku hijerarhiju, gdje se podaci mogu promatrati od

šire razine prema detaljnijoj, primjerice od godine prema mjesecu i danu. Time se korisniku omogućuje da iz općeg pregleda prijeđe na detaljniju analizu.

Roll-up je suprotna operacija od drill-downa. Ona omogućuje povratak s detaljnije razine na općenitiju razinu. Primjerice, ako se podaci promatraju po danima, roll-up omogućuje povratak na prikaz po mjesecu ili godini. Na taj način se podaci ponovno sažimaju i prikazuju na višoj razini.



OLAP operacije su korisne jer omogućuju interaktivno istraživanje podataka. Umjesto da se promatra samo jedan statičan prikaz, korisnik može mijenjati filtre, razinu detalja i perspektivu analize. U ovom projektu to omogućuje bolji pregled bankovnih transakcija i jednostavnije uočavanje obrazaca povezanih s prijevarama.

## 7.6. Zaključak OLAP analize

OLAP analiza u Power BI-ju pokazala je kako se podaci iz skladišta podataka mogu koristiti za interaktivno istraživanje i vizualizaciju bankovnih transakcija. Analiza je provedena nad konačnim skladištem podataka koje sadrži ukupno 200 000 transakcija dobivenih objedinjavanjem MySQL izvora i CSV izvora. Nakon što su podaci prethodno organizirani u star shemu i učitani u Power BI, bilo je moguće analizirati ih prema različitim dimenzijama.

Kroz izrađene dashboarde dobiven je pregled osnovnih pokazatelja, kao što su ukupan broj transakcija, ukupan iznos transakcija, prosječan iznos, broj prijevanih transakcija i udio prijevara. Time je omogućeno brzo razumijevanje glavnih vrijednosti u skupu podataka.

Posebna analiza prijevanih transakcija omogućila je promatranje prijevara prema tipu uređaja, kategoriji trgovca, lokaciji i tipu transakcije. Takav prikaz je koristan jer se prijevare ne promatraju samo ukupno, nego se mogu uspoređivati prema različitim obilježjima.

Prikazane OLAP operacije dodatno su pokazale mogućnosti analize podataka. Slice i dice omogućuju filtriranje podataka prema jednom ili više uvjeta, pivot mijenja pogled na podatke, dok drill-down i roll-up omogućuju prelazak između detaljnije i općenitije razine analize.

Na temelju izrađene OLAP analize može se zaključiti da Power BI omogućuje jednostavnije razumijevanje podataka iz skladišta. Korisnik može brzo mijenjati filtre, promatrati podatke iz više perspektiva i lakše uočavati obrasce povezane s bankovnim transakcijama i mogućim prijevarama.

## 8. ZAKLJUČAK

U ovom projektu prikazan je cijeli postupak pripreme i analize podataka o bankovnim transakcijama. Projekt je započeo odabirom i osnovnom analizom skupa podataka, kako bi se provjerilo je li skup prikladan za daljnju obradu. Analizom je utvrđeno da skup podataka sadrži dovoljan broj redaka i stupaca, nema nedostajućih vrijednosti te uključuje različite vrste podataka potrebne za izradu baze podataka i kasniju analizu.

Nakon početne analize izrađen je relacijski model podataka i implementirana je MySQL baza podataka. Podaci su organizirani u više povezanih tablica, čime je izbjegnuto spremanje svih podataka u jednu veliku tablicu. Time su podaci dobili jasniju strukturu i bili su pripremljeni za sljedeći korak, odnosno izradu dimenzijskog modela.

U dimenzijskom modelu izrađena je star shema, u čijem se središtu nalazi tablica činjenica `fact_bank_transaction`, dok se oko nje nalaze dimenzijske tablice. Takav model omogućuje jednostavniju analizu transakcija prema različitim dimenzijama, kao što su datum, korisnik, račun, trgovac, uređaj, vrsta transakcije, lokacija i valuta. U model su uključene i dodatne značajke, kao što su surogat ključevi, hijerarhije, sporo mijenjajuće dimenzije i degenerirana dimenzija.

Nakon izrade modela proveden je ETL proces. Podaci su dohvaćeni iz dva izvora: relacijske MySQL baze koja sadrži 80% početnog skupa podataka i CSV datoteke koja sadrži preostalih 20%. Ti su podaci zatim usklađeni, objedinjeni i pripremljeni za učitavanje u skladište podataka. Nakon punjenja dimenzijskih tablica i tablice činjenica napravljena je završna provjera kojom je potvrđeno da je u skladište učitano ukupno 200 000 transakcija i da su zapisi pravilno povezani s dimenzijama.

Završni dio projekta odnosio se na analizu podataka u Power BI-ju. U Power BI su učitani podaci iz skladišta, izrađen je model podataka, definirane su mjere i napravljeni dashboardi za pregled bankovnih transakcija i analizu prijevanih transakcija. Kroz vizualizacije je moguće pratiti ukupan broj transakcija, ukupne iznose, prosječne vrijednosti, broj prijevara i udio prijevarnih transakcija.

Prikazane su i osnovne OLAP operacije, kao što su slice, dice, pivot, drill-down i roll-up. One omogućuju promatranje podataka iz različitih perspektiva, filtriranje prema određenim uvjetima i prelazak između različitih razina detalja. Time je pokazano kako se podaci iz skladišta mogu koristiti za interaktivnu analizu i donošenje zaključaka.

Na temelju provedenog projekta može se zaključiti da skladište podataka i alati poslovne inteligencije omogućuju bolju organizaciju i analizu velikih skupova podataka. Podaci koji su na početku bili u obliku jedne CSV datoteke pretvoreni su u strukturirani analitički sustav koji omogućuje pregled bankovnih transakcija i lakše uočavanje mogućih prijevornih obrazaca. Projekt pokazuje kako se teorijski pojmovi iz područja skladišta podataka mogu primijeniti u praktičnom rješenju od početne obrade podataka do završne vizualizacije.